

Data Science Programmmentwurf

- Kurs: TINF22B
- Matrikelnummern: 6732014, 7191637

1. Business Understanding

1.1 Kontext

Sie sind Remote Worker in der Kreativbranche und möchten für 6 Monate mit einem Freund / einer Freundin ins Ausland. Dabei möchten Sie fünf Städte identifizieren, die in Frage kommen, und dabei möglichst verschiedene Optionen betrachten. Die Städte sollen in den Bergen liegen.

1.2 Profil

Die Person legt besonderen Wert auf günstiges Wohnen, preiswertes Essen (selbst gekocht oder unterwegs gekauft), niedrige Telefon- und Internetkosten. Die Person besitzt keinen Führerschein, nutzt öffentliche Verkehrsmittel und möchte zentral in einem belebten Stadtzentrum wohnen.

Neben finanziellen Aspekten ist der Person die Umgebung wichtig: Die Stadt sollte in den Bergen liegen, möglichst über 1000 Höhenmeter.

1.3 Ziel

Es sollen die individuellen Lebenshaltungskosten für die Person ermittelt werden, dazu wird ein Warenkorb für die Person definiert, welcher die Preise im Datensatz sinnvoll gewichtet.

Außerdem sollen Höhendaten genutzt werden, um die Höhenlage sowie die Bergigkeit der Umgebung zu bewerten.

Anhand der Analyse sollen dann Vorschläge für Städte gemacht werden. Die Vorschläge sollen dabei auf unterschiedlichen Kontinenten liegen.

2. Data Preparation & Feature Engineering

```
In [29]: import pandas as pd
import json

# Lade die CSV-Datei und benenne die Spalten in lesbarer Form um
df = pd.read_csv("data/cost-of-living.csv", index_col=0)
df.rename(columns=json.load(open("data/attribute_names.json")), inplace=True
```

2.1. Filtern der Daten

2.1.1. Filtern anhand von Qualität

Zu Beginn werden die Datensätze nach Qualität gefiltert.

```
In [30]: df = df[df["data_quality"]==1]
```

2.1.2. Fehlende Werte


Im nächsten Schritt wurde analysiert, welche Merkmale am meisten fehlende Werte aufweisen. Die zehn Merkmale mit den meisten fehlenden Werten wurden visualisiert.

```
In [31]: import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

df_numeric = df.select_dtypes(np.number)

# Die 10 Features ermitteln, bei denen am meisten Werte fehlen
features_with_most_missing = df_numeric.isna().sum().sort_values(ascending=F

# Darstellen als Seaborn plot
fig, ax = plt.subplots(figsize=(10,5))
ax = sns.barplot(features_with_most_missing)
ax.set(
    title="Anzahl der fehlenden Werte je Merkmal",
    ylabel="Anzahl der fehlenden Werte",
    xlabel="Merkmale",
)
ax.bar_label(ax.containers[0])
ax.set( axisbelow=True,)
plt.grid()
plt.xticks(rotation=90)
plt.show()
```




Auf Basis dieser Visualisierung wurde das Merkmal `primary_school` entfernt. Es weist nicht nur am meisten fehlende Werte auf, sondern spielt auch durch die Gewichtung im Warenkorb später keine Rolle (die Person hat keine Kinder geht nicht zur Schule).

Desweiteren wurde analysiert, wieviele Werte für wieviele Datensätze fehlen.

```
In [32]: df = df.drop("primary_school", axis="columns")

missing = df_numeric.T.isna().sum().value_counts()
ax = sns.barplot(data=missing)
ax.set(
    title="Wieviele Werte fehlen für wieviele Datensätze?",
    ylabel="Anzahl der Datensätze",
    xlabel="Anzahl der fehlenden Merkmale",
)
ax.bar_label(ax.containers[0])
ax.set(axisbelow=True)

plt.grid()
plt.show()
```



Diese Visualisierung beweist, dass die Anzahl der fehlenden Werte in den Daten akzeptabel ist. Zum Einen haben die meisten Datensätze gar keine fehlenden Werte, zum Anderen liegt die maximale Anzahl an fehlenden Werten bei 3, was im Vergleich zur Merkmalsanzahl sehr klein ist.

2.1.3. Duplikate

Im nächsten Schritt wird der Datensatz auf Duplikate untersucht. Da keine Duplikate vorliegen, muss deswegen auch kein Datensatz entfernt werden.

```
In [33]: city_duplicates = df["city"].value_counts(>1) # doppelte Städtenamen
# doppelte Städtenamen die nicht in verschiedenen Ländern vorkommen
city_country_duplicates = df[["city", "country"]].value_counts(>1)

print(f"Es gibt zwar {city_duplicates.sum()} doppelte Städtenamen, \
jedoch {city_country_duplicates.sum()} doppelte Städtenamen in verschiedenen
```

Es gibt zwar 8 doppelte Städtenamen, jedoch 0 doppelte Städtenamen in verschiedenen Ländern.

2.2. Anreichern der Daten

2.2.1. Länderkürzel & Kontinentnamen

Der Kontinent der einzelnen Städte wird mithilfe der Python-bibliothek `pycountry-convert` ermittelt. Hierbei werden zuerst die country codes ermittelt und abgespeichert, aus denen über die continent codes die Namen der Kontinente ermittelt werden können.

Einige wenige Ausnahmen, die nicht von der Bibliothek abgehandelt werden können, wurden manuell recherchiert und über die Dictionaries `exceptions` abgehandelt.

```
In [34]: import pycountry_convert as pc

# Umwandlung der Ländernamen in Länderkürzel
def country_name_to_alpha2(country_name):

    # Ausnahmefall
    exceptions = {
        "Bosnia And Herzegovina": "BA",
        "Trinidad And Tobago": "TT",
        "Isle Of Man": "IM",
        "Curacao": "CW",
        "Kosovo (Disputed Territory)": "XK",
    }
    if country_name in exceptions.keys():
        return exceptions[country_name]

    # Regelfall
    country_alpha2 = pc.country_name_to_country_alpha2(country_name)
    return country_alpha2

# Anwenden der Funktion auf die Spalte "country"
df["country_code"] = df["country"].apply(country_name_to_alpha2)

# Umwandlung der Länderkürzel in Kontinentkürzel und -namen
def alpha2_to_continent(alpha2):

    # Ausnahmefall
    exceptions = {
        "BA": "Europe",
        "TT": "South America",
        "IM": "Europe",
        "CW": "South America",
        "XK": "Europe",
    }
    if alpha2 in exceptions.keys():
        return exceptions[alpha2]

    # Regelfall
    continent_code = pc.country_alpha2_to_continent_code(alpha2)
    continent_name = pc.convert_continent_code_to_continent_name(continent_code)
    return continent_name

# Anwenden der Funktion auf die Spalte "country_code"
df["continent"] = df["country_code"].apply(alpha2_to_continent)
```

2.2.2. Geographische Koordinaten und Population

Der von [GeoNames](#) stammende Datensatz umfasst Städte mit mindestens 15000 Einwohnern oder Hauptstädte. Über ihn werden geographische Koordinaten und Populationsdaten angereichert. Im ersten Schritt wird er geladen und die relevanten Zeilen mithilfe des Arguments `usecols=` ausgewählt.

Um für eine Stadt die entsprechenden Daten in `cities` abzurufen, wird zuerst ein direkter Match mittels Städtename und Länderkürzel versucht. Scheitert dieser, wird überprüft, ob der Name der Stadt aus `df` als ein alternativer Name einer Stadt aus `cities` auftaucht. Alle Städte, die auch so nicht bearbeitet werden können, werden analog zum oberen Vorgehen mit `exceptions` abgehandelt.

```
In [35]: # Laden der Daten als Pandas DataFrame; Auswahl relevanter Spalten
cities = pd.read_table(
    "data/cities15000.txt",
    names=[
        "geonameid", "name", "asciiname", "alternatenames", "latitude", "lon
        "feature class", "feature code", "country code", "cc2", "admin1 code
        "admin3 code", "admin4 code", "population", "elevation", "dem", "tim
    ],
    usecols=["asciiname", "country code", "latitude", "longitude", "populati
)
# Vorverarbeitung: Eindeutige Stadt<->Staat Paare
cities = cities.groupby(["asciiname", "country code"]).first().reset_index()
# Vorverarbeitung: Umwandlung der alternatenames-Information von String zu L
cities["alternatenames"] = cities["alternatenames"].apply(lambda x: x.split(

exceptions = {
    "Windhoek": (-22.57, 17.083611, 486169),
    "Bhubaneshwar": (20.27, 85.84, 843402),
    "Sialkot City": (32.497222, 74.536111, 655852),
    "`Ajman": (25.4, 55.433333, 489176),
    "Kocaeli": (40.763889, 29.941667, 1997258),
    "Sandton": (-26.106944, 28.051667, 222415),
    "Jyvaskyla": (62.233056, 25.733056, 145887),
    "Targu-Mures": (46.533333, 24.566667, 116033),
    "Vasteras": (59.611111, 16.545833, 117746),
    "Gavle": (60.675556, 17.145833, 74884),
    "Southwick": (50.836, -0.239, 13195),
    "Gzira": (35.9049, 14.4938, 13021),
    "Joinville": (-26.301389, -48.843889, 515288),
    "Ra'ananna": (32.183333, 34.866667, 73999),
    "Walton upon Thames": (51.386797, -0.413394, 22834),
}

def fill_data(city_row):
    city_name = city_row["city"]
    country_code = city_row["country_code"]

    # Direkten Match mit Städtename und Länderkürzel suchen
```

```

city_name_matches = cities["asciiiname"]==city_name
country_code_matches = cities["country code"]==country_code
direct_matches = cities[city_name_matches & country_code_matches]
direct_match_exists = len(direct_matches)>0

if direct_match_exists:
    direct_match = direct_matches.iloc[0]
    city_row["latitude"] = direct_match["latitude"]
    city_row["longitude"] = direct_match["longitude"]
    city_row["population"] = direct_match["population"]
    return city_row

# Match über alternative Städtenamen ermitteln
alt_names_matches_index = cities["alternatenames"]\
    .apply(lambda alt_names_list: city_name in alt_names_list)
alt_names_matches = cities[alt_names_matches_index]
alt_names_match_exists = len(alt_names_matches)>0

if alt_names_match_exists:
    first_alt_match = alt_names_matches.iloc[0]
    city_row["latitude"] = first_alt_match["latitude"]
    city_row["longitude"] = first_alt_match["longitude"]
    city_row["population"] = first_alt_match["population"]
    return city_row

# Ausnahmen abhandeln, die nicht in Datensatz gefunden werden
if city_name in exceptions.keys():
    exception_data = exceptions[city_name]
    city_row["latitude"] = exception_data[0]
    city_row["longitude"] = exception_data[1]
    city_row["population"] = exception_data[2]
    return city_row

df = df.apply(fill_data, axis="columns")

```

2.2.3. Höhenmeter

Der Global Multiresolution Terrain Elevation Data-Datensatz (GMTED2010) stellt ein globales Höhenprofil in Rasterform dar. Verwendet wurde eine gemittelte Version des Datensatzes mit einer Auflösung von 900 Bogensekunden. Das bedeutet, die Erdoberfläche ist in ein Raster mit Zellen von jeweils 0,25° Breite und Länge unterteilt. Fragt man die Koordinaten eines konkreten Punkts ab, erhält man die mittlere Höhe des entsprechenden Rasterfeldes.

```

In [36]: import rasterio
from rasterio.plot import show

with rasterio.open("data/GMTED2010_averaged.tif") as src:
    fig, ax = plt.subplots(figsize=(10, 10))
    show(src, ax=ax)
    ax.set(
        title="Globale Höhendaten als Raster",
        xticks=[],


```

```

    yticks=[],
)
plt.show()

```

Globale Höhendaten als Raster



Die Funktion `get_height_at_coordinates` erlaubt die Umrechnung von Geokoordinaten auf Höhenmeter

```

In [37]: from rasterio.transform import rowcol

def get_height_at_coordinates(longitude, latitude, raster_file="data/GMTED20
    """
    Gibt die Höhe für gegebene geografische Koordinaten (Longitude, Latitude)

    :param longitude: Longitude-Wert (Längengrad)
    :param latitude: Latitude-Wert (Breitengrad)
    :param raster_file: Pfad zur Rasterdatei
    :return: Höhe an den angegebenen Koordinaten
    """
    with rasterio.open(raster_file) as src:
        # Transformiere die geografischen Koordinaten in Raster-Koordinaten
        row, col = rowcol(src.transform, longitude, latitude)

        # Hole die Höhendaten als numpy array
        height_data = src.read(1) # Liest das erste Band (Höhendaten)

        # Hole den Wert aus den Rasterdaten
        value = height_data[row, col]
        return value

# Beispielnutzung der Funktion
latitude, longitude = 48.782624819735624, 9.167036756166327 # Stuttgart
höhe = get_height_at_coordinates(longitude, latitude) # Der Wert ist die du
print(f"Höhe an der Position ({longitude}, {latitude}): {höhe}")

```

Höhe an der Position (9.167036756166327, 48.782624819735624): 294

```

In [38]: # Berechnung der Höhe für alle Städte
df["elevation"] = df.apply(
    lambda row: get_height_at_coordinates(row["longitude"], row["latitude"])

```



```
axis=1  
)
```

3. Data Exploration und Analyse

3.1 Allgemeine Voranalysen


3.1.1 Merkmalskorrelationen

Um einen Überblick über die Merkmale zu bekommen, werden diese zuallererst mit einer Korrelationsmatrix auf ihre Zusammenhänge überprüft.

Hierbei ist auffällig, dass ähnliche Produkte meist auch stark zueinander korrelieren (Autopreise, Wohnungspreise, Wasser und Cola, Früchte).

Weiter sticht ins Auge, dass Milch-, Schuhe- und Autopreise generell wenig mit Preisen für andere Produktarten korrelieren.

```
In [39]: import matplotlib.pyplot as plt  
import seaborn as sns  
  
numeric_columns = df.select_dtypes(np.number).drop(["latitude", "longitude",  
  
# Compute correlation matrix  
correlation_matrix = numeric_columns.corr()  
  
# Plot heatmap with all column names displayed  
plt.figure(figsize=(20, 15))  
sns.heatmap(correlation_matrix, annot=False, cmap="coolwarm", fmt=".2f", xti  
plt.title("Korrelationsmatrix")  
plt.xticks(rotation=90)  
plt.yticks(rotation=0)  
plt.show()
```



3.1.2 Erstellung eines Warenkorbs

Viele der Features im Datensatz beziehen sich auf Preise. Die Wichtigkeit eines einzelnen Preismerkmals ist jedoch von Person zu Person unterschiedlich. Um die Kauf- und Lebensweise, die in Kapitel 1 spezifiziert wurde, abzubilden wurde mittels eines "Warenkorbs" eine Gewichtung für die einzelnen Merkmale vorgenommen. Diese stellt ein auf die Person angepasstes Preis-rating der einzelnen Städte dar und soll die **Monatsausgaben** abbilden.

Um eine generelle Analyse der Kosten durchführen zu können werden die Kosten dann noch in Kategorien eingeteilt.

```
In [40]: # Kopie des DataFrames für die Analyse
df_analyze = df.copy()

# JSON-Daten laden
with open("data/kath_basked.json", "r") as file:
    weights = json.load(file)

# Funktion zur Berechnung der gewichteten Werte für jede Kategorie
def calculate_weighted_values(df_analyze, weights):
```

```

weighted_values = {}
for category, items in weights.items():
    weighted_values[category] = df_analyze[list(items.keys())].mul(pd.Series(items, index=items.keys(), data=weights[category]))
return weighted_values

# Gewichtete Werte berechnen
weighted_values = calculate_weighted_values(df_analyze, weights)

# Gewichtete Werte als neue Spalten hinzufügen
for category, values in weighted_values.items():
    df_analyze[f"weighted_{category}"] = values

# Gruppierte Balkendiagramm für gewichtete Attribute nach Kontinent
weighted_columns = [col for col in df_analyze.columns if col.startswith("weighted_")]
df_analyze["weighted_basket"] = df_analyze[weighted_columns].sum(axis=1)

```

3.1.3 Kostenindex nach Kategorie

Um einen besseren Überblick über die Kosten zu bekommen, werden die einzelnen Kosten in 6 Kategorien eingeteilt.

Die Auswertung der Boxplots zeigt, dass Die Wohnungskosten länderübergreifend den größten Teil der Kosten ausmachen, gefolgt von Restaurantkosten, die deutlich über den allgemeinen Kosten für Essen und Trinken liegen.

Kleidung ist meist billiger, kann aber vereinzelt auch sehr teuer werden.

Dienstleistungen und Transport sind durchweg vergleichsweise günstig.

```

In [38]: def compute_groupings(df_analyze, group_by_col):
# Gruppieren die Daten und berechne den Mittelwert für jede Kategorie
grouped_data = df_analyze.groupby(group_by_col)[weighted_columns].mean()

# Sortiere die Daten nach der größten Gesamtausgabe
grouped_data["sum"] = grouped_data.sum(axis=1)
grouped_data = grouped_data.sort_values(by="sum", ascending=False)

# Entferne die Spalten und benenne die Spalten um
grouped_data.drop(columns=["sum"], inplace=True)
grouped_data.rename(columns={
    "weighted_restaurants": "Restaurants",
    "weighted_food_and_drinks": "Essen und Trinken",
    "weighted_transportation": "Transport",
    "weighted_housing": "Wohnen",
    "weighted_utilities_and_services": "Versorgung und Dienstleistungen",
    "weighted_clothing": "Kleidung"
}, inplace=True)
return grouped_data


grouped_df = compute_groupings(df_analyze, "continent")

fig, axes = plt.subplots(2, 3, figsize=(8, 6))

```

```
# Iteriere über die Kategorien und erstelle individuelle Boxplots
for ax, column in zip(axes.flat, grouped_df.columns):
    sns.boxplot(data=grouped_df[column], ax=ax)
    ax.set(
        title=column,
        xlabel="",
        ylabel="Kosten (in US Dollar)",
        axisbelow=True
    )
plt.grid()

plt.tight_layout()
plt.show()
```



3.2 Auswertung nach Kontinenten


3.2.1. Generelle Verteilung

Zuallererst soll ein grober Überblick über die Verteilung der Städte in den Kontinenten gewonnen werden. Hierzu werden links die Anzahl der Städte pro Kontinent und rechts die Einwohner nach Kontinent visualisiert.

```
In [42]: fig, axes = plt.subplots(1, 2, figsize=(18, 6), sharey=False)
```

```
# Diagramm 1: Bevölkerung nach Kontinent
df_analyze.groupby("continent")["population"].sum().sort_values(ascending=False,
    kind="bar", ax=axes[1], title="Bevölkerung", ylabel="Einwohnerzahl", xla
)
axes[1].set(axisbelow=True)
axes[1].grid(visible=True)

# Diagramm 2: Zahl der Städte nach Kontinent
df_analyze.groupby("continent")["city"].count().sort_values(ascending=False)
    kind="bar", ax=axes[0], title="Anzahl der Städte", ylabel="Anzahl der St
)
axes[0].set(axisbelow=True)
axes[0].grid(visible=True)
plt.tight_layout()
plt.show()
```



3.2.2. Ausgabenstruktur

Die folgende Grafik zeigt, dass sich die monatlichen Lebenshaltungskosten des definierten Warenkorbs zwischen den Kontinenten deutlich unterscheiden. Der prozentuale Anteil der einzelnen Kategorien (z. B. Essen, Wohnen etc.) an den Gesamtkosten bleibt jedoch weitgehend ähnlich.


```
In [43]: def plot_expenses(df_analyze, group_by_col, title):

    grouped_data = compute_groupings(df_analyze, group_by_col)

    ax = grouped_data.plot(
        kind="bar",
        stacked=True,
        figsize=(12, 8),
        title=title,
        ylabel="Durchschnittliche Kosten des Warenkorbs",
        xlabel="Kontinent",
        colormap="tab10",
    )
    #plt.xticks(rotation=45)
    plt.legend(title="Kategorien", bbox_to_anchor=(1.05, 1), loc='upper left')
    plt.tight_layout()
    ax.set(axisbelow=True)
    plt.grid()
```

```
plt.show()
```

```
plot_expenses(df_analyze, "continent", "Ausgabenindex nach Kontinent (in ver
```



3.2.3. Höhendaten

Im Folgenden wird der Einfachheit halber davon gesprochen, dass eine Stadt auf einer bestimmten Höhe (in Metern) liegt. Damit ist gemeint, dass sowohl die Stadt selbst als auch ihr Umland im entsprechenden Rasterfeld im Mittel auf dieser Höhe liegen. Diese Vereinfachung ergibt sich aus der begrenzten Auflösung des Höhenprofils, ist jedoch durchaus sinnvoll: Eine Stadt wie Innsbruck liegt zwar im Tal, ist jedoch von zahlreichen Bergen umgeben. Da auch diese Höhenzüge in die Mittelwertberechnung des Rasters einfließen, wird das Umland realistisch mitberücksichtigt. Aus diesem Grund wurde im beigelegten Datensatz die Auflösung des Rasters vorab reduziert.

Im nächsten Schritt werden mit Hilfe von Histogrammen die Höhenverteilungen der Städte der Kontinente visualisiert. Hierbei fallen große Unterschiede zwischen den Kontinenten auf: Während vereinzelte Städte in Ozeanien gerade einmal auf 600 Meter ü. NN ragen, liegt eine Vielzahl an Städten in Südamerika zwischen 2000 und 4000 Meter ü. NN. Asien und Afrika liegen mit bis zu 2500/3000 Meter ü. NN im oberen Mittelfeld, gefolgt von Europa, dessen Städte knapp die 1500 Meter Marke nicht erreichen.


Im Bezug auf die Bergigkeit steht Südamerika somit ungeschlagen.

```
In [44]: continents = df_analyze["continent"].unique()
fig, axes = plt.subplots(2, 3, figsize=(12, 8))

for ax, continent in zip(axes.flat, continents):
    group = df_analyze[df_analyze["continent"] == continent]
    sns.histplot(
        group["elevation"],
        kde=False,
        bins=10,
        alpha=0.6,
        ax=ax
    )
    ax.set_title(f"Histogramm der Höhenlage für {continent}")
    ax.set_xlabel("Höhenmeter (m)")
    ax.set_ylabel("Anzahl der Städte")
    ax.set(axisbelow=True)
    ax.grid()

# Entferne leere Subplots, falls weniger als 6 Kontinente vorhanden sind
for ax in axes.flat[len(continents):]:
    ax.axis("off")

plt.tight_layout()
plt.show()
```




3.3 Auswertung nach Ländern

3.3.1. Anzahl der Städte über 1000 NN

Vorab wird nach Städten gefiltert, die über 1000 Meter ü. NN liegen, um die gewünschte Bergigkeit sicherzustellen. Diese Filterung schon hier vorzunehmen macht die folgenden Auswertungen übersichtlicher.

```
In [45]: df_analyze = df_analyze[df_analyze["elevation"] > 1000]


ax = df_analyze.groupby("country")["city"].count().sort_values(ascending=False,
    kind="bar",
    title="Anzahl der Städte über 1000m Höhe nach Land",
    ylabel="Anzahl der Städte",
    xlabel="Kontinent",
    figsize=(10, 5)
)
ax.set(axisbelow=True)
plt.grid()
plt.show()
```



3.3.2 Ausgabenverteilung nach Land

Auch bei der Ausgabenverteilung nach unterschiedlichen Ländern bleibt der Anteil der Kategorien an den Gesamtkosten über die unterschiedlichen Länder generell stabil. Trotzdem gibt es ein paar Ausnahmen, siehe beispielsweise Afghanistan und Äthiopien.

```
In [46]: plot_expenses(df_analyze, "country", "Ausgabenindex nach Land (in verschiede
```





3.3.3. Betrachtung Internetkosten

Generell ist für die Person eine stabile internetverbindung wichtig (Remote Worker), eine Analyse der Merkmale hatte ergeben, dass in einigen weniger stark entwickelten Ländern Internetkosten sehr hoch sind. Da dies nicht mit dem generellen Preisniveau der länder übereinstimmt ist dies ein Hinweis auf eine schlechte Internetverfügbarkeit.

```
In [47]: df_analyze["internet_coeffitiant"] = df_analyze["internet"] / df_analyze["we

highest_internet_costs = df_analyze.groupby("country")["internet_coeffitiant"]
ax = highest_internet_costs.head(20).plot(
    kind="barh",
    title="Internetkosten im Verhältnis zu den Lebenshaltungskosten",
    ylabel="Land",
    xlabel="Internetkosten in $",
    figsize=(10, 5)
)
ax.set(axisbelow=True)
plt.grid()
plt.show()
```



3.4 Auswahl der Städte

Um eine zuverlässige Internetverbindung sicherstellen zu können, werden Städte aussortiert, bei denen die Internetkosten mindestens 10 % der Lebensunterhaltungskosten betragen. Um im Budget zu bleiben werden Städte ebenfalls aussortiert, wenn deren Lebensunterhaltungskosten bei mindestens 3000 € liegen.

```
In [48]: sel = (df_analyze["internet_coeffitiant"] < 0.1) & (df_analyze["weighted_bas"] < 3000)
df_analyze = df_analyze[sel]
```


Die folgende Karte visualisiert die ausgewählten Städte. Dabei repräsentiert die Größe der Kreise die durchschnittliche Höhenlage (in Metern) der jeweiligen Stadt bzw. ihres Umlands, während die Farbgebung den Kostenindex widerspiegelt.

```
In [49]: import kaleido
import plotly.express as px
from IPython.display import Image

fig = px.scatter_geo(
    df_analyze,
    lat="latitude",
    lon="longitude",
    size="elevation",
    color="weighted_basked",
    projection="natural earth",
    height=600,
    width=1000,
)
fig.update_layout(
    title="Verteilung der ausgewählten Länder auf der Welt",
    showlegend=True,
```

```
)
selected_countries_image = fig.to_image()
Image(selected_countries_image)
```

Out[49]: Verteilung der ausgewählten Länder auf der Welt



Um die Vorschläge möglichst vielfältig zu gestalten, wird für jeden Kontinent ein Vorschlag gemacht. Dabei wurde jeweils das Land mit den niedrigsten Lebenshaltungskosten ausgewählt. Die endgültigen Vorschläge sind der Tabelle zu entnehmen.

```
In [50]: columns = ["city", "country", "continent", "weighted_basked", "elevation"]
min_country_of_continent = df_analyze.groupby("continent")["weighted_basked"]
df_analyze.loc[min_country_of_continent, columns].sort_values("continent")
```

Out[50]:

	city	country	continent	weighted_basked	elevation
3477	Hargeysa	Somalia	Africa	885.59875	1225
1955	Konya	Turkey	Asia	533.70250	1302
2173	Innsbruck	Austria	Europe	2311.37000	1476
577	Aguascalientes	Mexico	North America	914.93000	1948
970	Manizales	Colombia	South America	518.70375	1264

4. Modelling und Evaluation Regression

Der Apfelpreis wird anhand vorhandener Features im Datensatz vorhergesagt. Dazu wird zunächst eine Feature-Selektion durchgeführt und anschließend ein Estimator verwendet, um den Preis zu prognostizieren. Um einen Überblick zu gewinnen werden verschiedene Selektionsverfahren, Estimatoren sowie unterschiedliche Anzahlen an Features getestet. Jedes Ergebnis (R^2 und RMSE) wird im Rahmen einer 5-fachen Kreuzvalidierung ermittelt.

Wichtig: Wenn die Feature-Auswahl beispielsweise auf der Korrelation zwischen dem Apfelpreis und den anderen Features basiert, werden für die Korrelationsberechnung ausschließlich die Trainingsdaten verwendet. Alles andere würde zu einer Vermischung von Trainings- und Testdaten führen – denn auch die Feature-Auswahl stellt eine Trainingsentscheidung dar. Im Code wird dies dadurch sichergestellt, dass die gesamte Pipeline aus Selektion und Estimator in die Kreuzvalidierung eingebunden wird – und nicht nur der Estimator allein.

Ca 5-10 min Ausführungszeit auf AMD Ryzen 7 5700

```
In [ ]: from sklearn.model_selection import cross_val_score
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
from sklearn.neighbors import KNeighborsRegressor
from sklearn.svm import SVR
from sklearn.feature_selection import SelectKBest, f_regression, mutual_info
from sklearn.pipeline import Pipeline

n_values = list(range(1, 20)) # Verschiedene Werte von n, über die iteriert

# Initialisiere Speicher für Ergebnisse
results = []

# Bewertungsfunktion für die Auswahl von Features anhand der Korrelation mit
def compute_correlation(X, y):
    """Berechnet die Korrelation zwischen Features und Zielwert.
    Argumente:
        X: ndarray, Form (n_samples, n_features)
        y: Zielvariable
    Rückgabe:
        ndarray, Form (n_features,)
        Korrelationskoeffizienten zwischen jedem Feature und der Zielvar
    """
    # Numpy-Trick: Die Funktion gibt eigentlich eine Matrix zurück, die letz
    # enthält die gewünschten Koeffizienten
    return np.abs(np.corrcoef(X.T, y)[-1, :-1])

numeric_columns = df.select_dtypes(np.number).dropna()
x = numeric_columns.drop(columns=["apples"])
y = numeric_columns["apples"]

for n in n_values:

    # Definiere Methoden zur Feature-Auswahl
```

```

feature_selection_methods = {
    "f_regression": SelectKBest(score_func=f_regression, k=n),
    "mutual_info": SelectKBest(score_func=mutual_info_regression, k=n),
    "correlation": SelectKBest(score_func=compute_correlation, k=n),
}

# Definiere Modelle
base_estimators = {
    "Lineare Regression": LinearRegression(),
    "SVR": SVR(kernel="rbf"),
    "Random Forest": RandomForestRegressor(n_estimators=100),
    "K-Nearest Neighbors": KNeighborsRegressor(n_neighbors=5),
}

# Erstelle Pipelines für alle Kombinationen aus Feature-Auswahl und Modelle
estimators = {
    (fs_name, est_name): Pipeline([
        ("feature_selection", fs_method),
        ("estimator", estimator)
    ])
    for fs_name, fs_method in feature_selection_methods.items()
    for est_name, estimator in base_estimators.items()
}

# Trainiere und bewerte jedes Modell
for name, estimator in estimators.items():
    scores_r2 = cross_val_score(estimator, x, y, cv=5, scoring="r2")
    scores_rmse = np.sqrt(-cross_val_score(estimator, x, y, cv=5, scoring="rmse"))

    results.append({
        "n": n,
        "Feature-Auswahl": name[0],
        "Modell": name[1],
        "RMSE": scores_rmse.mean(),
        "R²": scores_r2.mean(),
        "RMSE Std": scores_rmse.std(),
        "R² Std": scores_r2.std()
    })

# Ergebnisse mit MultiIndex anzeigen
results_df = pd.DataFrame(results).set_index(["Modell", "Feature-Auswahl"])

```

Hinweis: Vor allem bei der Selektion zeigten sich univariate Verfahren wie beispielsweise Forward- oder Backward-Selektion als wenig vielversprechend, weswegen diese in unserem Vergleich nicht weiter berücksichtigt wurden. Für eine Auswertung anderer Estimatoren und Selektionsverfahren muss lediglich in den Dictionaries `feature_selection_methods` oder `base_estimators` eine Zeile ergänzt und ein entsprechendes `sklearn`-Objekt übergeben werden.

4.1 Ergebnisse

Die folgenden Plots zeigen den Verlauf der Metriken für die einzelnen Kombinationen aus Estimator und Selektionsverfahren. Kombinationen, die eine sehr schwache Performance gezeigt haben – darunter die Ansätze mit SVR und K-Nearest Neighbors – wurden aus Gründen der Übersichtlichkeit entfernt.

```
In [52]: # Erstelle eine Liste der Metriken
metrics = ["RMSE", "R2"]


# Erstelle eine Figure mit Subplots
fig, axes = plt.subplots(1, len(metrics), figsize=(15, 5), sharex=True)

# Iteriere über die Metriken und erstelle für jede einen separaten Plot
for i, metric in enumerate(metrics):
    ax = axes[i]
    for (model, feature_selection), subset in results_df.groupby(["Modell",

        if model in ["SVR", "K-Nearest Neighbors"]:
            continue
        if feature_selection in ["f_regression"]:
            continue

        ax.plot(
            subset["n"],
            subset[metric],
            marker="o",
            label=f"{model} - {feature_selection}"
        )
    ax.set_title(f"Verlauf der {metric} in Abhängigkeit von n")
    ax.set_xlabel("n")
    ax.set_ylabel(metric)
    ax.legend(title="Model - Feature Selection", bbox_to_anchor=(1.05, 1), 1
    ax.grid(True)

# Passe das Layout an
plt.tight_layout()
plt.show()
```



Varianzbetrachtung

```
In [53]: results_df[results_df["n"] == 6].groupby(["Modell", "Feature-Auswahl"]).mean
```

Out[53]:

		n	RMSE	R ²	RMSE Std	R ² Std
Modell	Feature-Auswahl					
Random Forest	mutual_info	6.0	0.586419	0.812225	0.152758	0.061984
	f_regression	6.0	0.605491	0.791828	0.133110	0.053760
	correlation	6.0	0.607464	0.796248	0.134168	0.057903
Lineare Regression	correlation	6.0	0.637497	0.772997	0.089315	0.027766
	f_regression	6.0	0.637497	0.772997	0.089315	0.027766
	mutual_info	6.0	0.655693	0.755492	0.090021	0.022582
K-Nearest Neighbors	correlation	6.0	0.689641	0.719148	0.294067	0.205262
	f_regression	6.0	0.689641	0.719148	0.294067	0.205262
SVR	correlation	6.0	0.710194	0.706315	0.293809	0.201696
	f_regression	6.0	0.710194	0.706315	0.293809	0.201696
K-Nearest Neighbors	mutual_info	6.0	0.712927	0.697509	0.145327	0.083244
SVR	mutual_info	6.0	0.819772	0.626426	0.183891	0.098470

4.2 Fazit

Bei der Anzahl der Features fällt auf, dass bereits eine kleine Auswahl (etwa sechs Features) ausreicht, um eine Vorhersage zu treffen, die sich durch zusätzliche Features nicht weiter verbessern lässt. Dies lässt sich grundsätzlich damit erklären, dass nur ein geringer Teil der Features tatsächlich eine starke Korrelation mit dem Apfelpreis aufweist.

Zwar konnte mit dem Random-Forest-Ansatz ein besseres Ergebnis als mit der linearen Regression erzielt werden, insgesamt unterscheidet sich die Performance der Modelle jedoch nicht signifikant.

Generell zeigt sich beim Random-Forest-Ansatz ($n = 6$) eine höhere Standardabweichung der Metriken über die einzelnen Folds hinweg im Vergleich zur linearen Regression. Der R^2 -Wert zeigt hingegen ein umgekehrtes Verhalten.

Insgesamt lässt sich anhand dieses Beispiels kein klarer Trend in Bezug auf das Bias-Variance-Trade-off zwischen den Verfahren erkennen (auch nicht in Bezug auf die anderen Verfahren).

5. Unüberwachtes Lernen - Clustern

Auch beim unüberwachten Lernen, also dem Clustern der Städte, wurden mehrere Verfahren ausprobiert. Bei nichtdeterministischen Verfahren wie KMeans, bei denen einzelne Teile des Verfahrens auf Zufall basieren, wurde die Berechnung mit zufälligen Random Seeds insgesamt zehnmal durchgeführt und ein Durchschnittswert für die Scores berechnet. Die Verfahren wurden für verschiedene Clustergrößen zwischen 2 und 40 in Zweierschritten angewendet.

```
In [54]: from sklearn.cluster import KMeans, SpectralClustering, AgglomerativeClustering
from sklearn.metrics import silhouette_score, calinski_harabasz_score, davies_bouldin_score
from sklearn.preprocessing import StandardScaler

# Selektiere numerische Spalten
numeric_columns = df.select_dtypes(np.number)

# Skalieren der Daten
scaler = StandardScaler()
scaled_numeric = pd.DataFrame(scaler.fit_transform(numeric_columns))

# Entferne Zeilen mit fehlenden Werten
not_na = ~numeric_columns.isna().any(axis=1)
data_to_cluster = scaled_numeric.dropna()

# Initialisiere Speicher für Ergebnisse
results = []

# Definiere Clustering-Methoden
clustering_methods = {
    "KMeans": lambda n_clusters: KMeans(n_clusters=n_clusters, random_state=42),
    "Agglomerative": lambda n_clusters: AgglomerativeClustering(n_clusters=n_clusters),
    "SpectralClustering": lambda n_clusters: SpectralClustering(n_clusters=n_clusters)
}

# Clustergrößen, die evaluiert werden sollen
cluster_sizes = list(range(2, 40, 2))

cluster_dict = {}

# Führe Clustering für jede Methode und Clustergröße durch
for method_name, method in clustering_methods.items():
    for n_clusters in cluster_sizes:
        # Iterationen für Methoden, die Zufälligkeit enthalten
        iterations = 1
        if method_name in ["KMeans", "BisectingKMeans"]:
            iterations = 10
        for i in range(iterations):
            clusters = method(n_clusters).fit_predict(data_to_cluster)
```



```

cluster_dict[(method_name, n_clusters)] = clusters

# Berechne Metriken für die Cluster
silhouette_avg = silhouette_score(data_to_cluster, clusters)
calinski_harabasz = calinski_harabasz_score(data_to_cluster, clusters)
davies_bouldin = davies_bouldin_score(data_to_cluster, clusters)
results.append({
    "Method": method_name,
    "Cluster": n_clusters,
    "Silhouette Score": silhouette_avg,
    "Calinski-Harabasz Index": calinski_harabasz,
    "Davies-Bouldin Index": davies_bouldin
})

# Erstelle ein DataFrame mit einem MultiIndex
metrics_df = pd.DataFrame(results)
metrics_df = metrics_df.groupby(["Method", "Cluster"]).mean().reset_index()

metrics_df.set_index(["Method", "Cluster"], inplace=True)
metrics_df.sort_index(inplace=True)

```

5.1 Einfluss der Clustergröße

Das nachfolgende Diagramm zeigt den Verlauf der Metriken für verschiedene Verfahren in Abhängigkeit von der Clustergröße.

```

In [55]: import matplotlib.pyplot as plt

# Erstelle eine Liste der Metriken
metrics = ["Silhouette Score", "Calinski-Harabasz Index", "Davies-Bouldin Index"]


# Erstelle eine Figure mit Subplots
fig, axes = plt.subplots(1, len(metrics), figsize=(18, 5), sharex=True)

# Iteriere über die Metriken und erstelle für jede einen separaten Plot
for i, metric in enumerate(metrics):
    ax = axes[i]
    for method in metrics_df.index.get_level_values("Method").unique():
        subset = metrics_df.loc[method]
        ax.plot(
            subset.index,
            subset[metric],
            marker="o",
            label=method
        )
    ax.set_title(f"Verlauf der {metric} für verschiedene Algorithmen")
    ax.set_xlabel("Anzahl der Cluster")
    ax.set_ylabel(metric)
    ax.legend(title="Methode")
    ax.grid(True)

# Passe das Layout an

```

```
plt.tight_layout()
plt.show()
```



Der Silhouette Score (hoch = gut getrennt & kompakt) fällt bei allen Verfahren nach wenigen Clustern stark ab. Das selbe gilt für den Calinski-Harabasz Index (hoch = gutes Verhältnis zwischen interner Streuung & Clusterabstand). Der Davies-Bouldin Index (niedrig = besser getrennte Cluster) ist bei Agglomerative über weite Bereiche am niedrigsten, während BisectingKMeans konstant schlechtere Werte liefert.

5.2 Clustervisualisierung

Die folgende Grafik zeigt die geografische Verteilung der Cluster auf einer Weltkarte – jeweils für verschiedene Clusterzahlen und Lernverfahren.

```
In [56]: from plotly.subplots import make_subplots

# Cluster-Konfigurationen
cluster_configs = [
    ("KMeans", 2), ("KMeans", 4), ("KMeans", 10),
    ("Agglomerative", 2), ("Agglomerative", 4), ("Agglomerative", 10)
]

# Subplots erstellen
fig = make_subplots(
    rows=3, cols=2,
    subplot_titles=[f"{method} ({n_clusters} Cluster)" for method, n_clusters in cluster_configs],
    specs=[[{"type": "scattergeo"}] * 2] * 3,
    vertical_spacing=0.05, # Abstand zwischen den Zeilen
    horizontal_spacing=0.01 # Abstand zwischen den Spalten
)

# Daten für jede Cluster-Konfiguration hinzufügen
for i, (method, n_clusters) in enumerate(cluster_configs):
    row, col = divmod(i, 2)
    display_data = df[not_na].copy()
    display_data["cluster"] = cluster_dict[(method, n_clusters)].astype("object")

    scatter_geo = px.scatter_geo(
        display_data, lat="latitude", lon="longitude", color="cluster",
        hover_name="city", hover_data=["country", "elevation"],
        projection="natural earth",
    )
```

```


for trace in scatter_geo.data:
    fig.add_trace(trace, row=row + 1, col=col + 1)

# Layout aktualisieren
fig.update_layout(
    title_text="Clustering der Städte",
    showlegend=False,
    margin={"t": 50, "b": 20, "l": 0, "r": 0},
)

Image(fig.to_image(format="png", width=1200, height=900))

```

Out[56]:



Generell fällt auf, dass die Cluster wohlhabendere Länder bzw. solche mit unterschiedlichen Lebenshaltungskosten sinnvoll klassifizieren – und das über alle Clustergrößen hinweg. Auch wenn die mathematischen Metriken bei größeren Clusterzahlen tendenziell abnehmen, erscheint die Klassifikation für z.B. $n=10$ dennoch plausibel. Die Verfahren scheinen anhand der Preisstruktur verschiedener Produkte sogar einzelne Länder wie etwa England oder die Schweiz gezielt zu identifizieren (bei $n=10$).

In Bezug auf Aufgabe 1 könnten die Cluster zwar einen Anhaltspunkt für Preisniveaus einzelner Länder bieten, jedoch ist zu beachten, dass der speziell definierte Warenkorb eine maßgeschneiderte Metrik erlaubt. Ein solcher ist vor allem besser interpretierbar, da er nicht unter durch das Lernverfahren bedingten Unregelmäßigkeiten leidet. Aus

diesem Grund wurde entschieden, die Cluster nicht als Grundlage für die Städteauswahl heranzuziehen.

6. Deployment

Um eine möglichst passende Stadt für den geplanten 6-monatigen Aufenthalt im Ausland zu finden, haben wir insgesamt ca. 910 Städte auf der ganzen Welt auf die unterschiedlichsten Eigenschaften untersucht. Nach unserer ausgiebigen Analyse sind wir zum Ergebnis gekommen, dass sich die folgenden Städte unter den passendsten weltweit befinden:

Stadt	Land	Kontinent	Kostenfaktor	Umgebungshöhe
Hargeysa	Somalia	Africa	885.6	1225
Konya	Turkey	Asia	533.7025	1302
Innsbruck	Austria	Europe	2311.37	1476
Aguascalientes	Mexico	North America	914.93	1948
Manizales	Colombia	South America	518.70	1264

Die Städte befinden sich nicht nur in einer hohen Umgebung; sie erweisen sich im Vergleich zu anderen Ländern des jeweiligen Kontinents auch als preiswert. Unser Ziel war es, aus möglichst unterschiedlichen Gegenden Vorschläge zu machen: die Städte überspannen somit ganze 5 Kontinente. Um eine tolle Arbeitserfahrung zu ermöglichen, haben wir zudem Städte ausgeschlossen, deren Daten auf eine schlechte Internetverbindung hinweisen.

Doch wie sind wir zu diesem Ergebnis gekommen?

Zuallererst haben wir wichtige Informationen wie die der Höhe angereichert.

Im nächsten Schritt haben wir die einzelnen Kontinente auf Anzahl der Städte, Höhenlage und Preis analysiert. Das persönliche Kaufverhalten für einzelne Produkte haben wir hier mit einer eigens erstellten Gewichtung - quasi einem Warenkorb - berücksichtigt. Diese Analyse ergab, dass Südamerika im Schnitt die höchsten Städte aufweist und mit Afrika und Asien auch am preiswertesten ist.

Dann haben wir die Analyse auf einzelne Länder verfeinert, wobei wir uns hier auf Städte beschränken, deren Umgebung über 1000 Meter NN liegt. Im nächsten Schritt haben wir Städte ausgeschlossen die zu teuer sind oder eine zu unzuverlässige Internetverbindung aufweisen. Die folgende Grafik zeigt die hierbei übrig gebliebenen Städte, wobei die Größe der Kreise die Umgebungshöhe der Stadt darstellt. Von diesen Städten haben wir uns jeweils für die preiswerteste Stadt des jeweiligen Kontinents entschieden.

Wir hoffen, mit dieser datenbasierten Empfehlung eine gute Grundlage für die Entscheidung gelegt zu haben. Für die Zeit im Ausland wünschen wir das Beste!

```
In [57]: Image(selected_countries_image)
```

Out[57]: Verteilung der ausgewählten Länder auf der Welt

